



Логистическая регрессия

Весна 2024 – Лекция 3


Задача классификации



Задача классификации



Задача классификации




Формализация задачи

- Задача классификации на 2 класса $Y=\{1,-1\}$
- Обучающая выборка $X=(x_i, y_i), i=1, L$
- Построить алгоритм классификации $a(x, w) = \text{sign } f(x, w)$

$f(x, w) = 0$ – разделяющая поверхность

Отступ

- $f(x, w) = 0$ – разделяющая поверхность
- $M_i(w) = y_i f(x_i, w)$ – отступ объекта i (Margin)
- $M_i(w) < 0 \Rightarrow$ ошибка алгоритма а на объекте i




Функционал эмпирического риска

- $M_i(w) < 0 \Rightarrow$ ошибка алгоритма а на объекте I
- Эмпирический риск
 - $Q(w) = \sum_i^L [M_i(w) < 0]$
 - Гладкая аппроксимация $Q \leq Q'(w) = \sum_i^L L(M_i(w))$
 - $Q \rightarrow \min$

Аппроксимации

Часто используемые непрерывные функции потерь $\mathcal{L}(M)$:



$$V(M) = (1 - M)_+$$

$$H(M) = (-M)_+$$

$$L(M) = \log_2(1 + e^{-M})$$

$$Q(M) = (1 - M)^2$$

$$S(M) = 2(1 + e^M)^{-1}$$

$$E(M) = e^{-M}$$

— кусочно-линейная (SVM);

— кусочно-линейная (Hebb's rule);


— логарифмическая (LR);

— квадратичная (FLD);


— сигмоидная (ANN);

— экспоненциальная (AdaBoost);

Эмпирический подход



Аппроксимация для логистической регрессии



$$L(M) = \log(1 + e^{-M})$$


Логистическая регрессия на 1 слайд

- $L = \log(1+e^{-M})$
- $Q'(w) = \sum_i^L \log(1 + \exp(-M_i)) \rightarrow \min_w$
- Оптимизация градиентным спуском
- $a(x_i, w_i) = \text{sign}(x_i, w_i)$

Спин-офф: функция сигмоиды

- Посмотрим на функцию

- $$\sigma(M) = \frac{1}{1 + \exp(-M)}$$




Спин-офф: функция сигмоиды

- Посмотрим на функцию

- $\sigma(M) = \frac{1}{1+\exp(-M)}$

- Ассимптоты

- $\sigma(-\infty) = 0$
 - $\sigma(+\infty) = 1$
 - $\sigma(M) = 0.5$



- Looks like вероятность !


Спин-офф: функция сигмоиды

- Посмотрим на функцию

- $\sigma(M) = \frac{1}{1+\exp(-M)}$

- Ассимптоты

- $\sigma(-\infty) = 0$
 - $\sigma(+\infty) = 1$
 - $\sigma(M) = 0.5$



- Looks like вероятность !

- $p(M_i) = \frac{1}{1+\exp(-M_i)}$ - "вероятность правильной классификации объекта I"

Логистическая регрессия

- $Q'(w) = -\sum_i^L \log(p_i) \rightarrow \min_w$
- $Q'(w) = \sum_i^L \log(p_i) \rightarrow \max_w$ – максимизируем 'вероятности' правильных классификаций
- $a(x_i, w_i) = \text{sign}(x_i, w_i) \leftrightarrow a(x_i, w_i) = \text{sign}\left(\frac{1}{1 + \exp(-(x_i, w_i))} - 0.5\right)$
- Можем даже уточнить алгоритм
 - $a(x_i, w_i) = \text{sign}\left(\frac{1}{1 + \exp(-(x_i, w_i))} - \text{th}\right)$

Логистическая регрессия: log-loss

- Другая формализация – $Y = \{0,1\}$
- $Q^{(w)} = -\sum_i^L y_i \log(p_i) + (1 - y_i) \log(1 - p_i)$
- Чаще всего это называют log-loss

Логистическая регрессия


- На этом вроде бы и все
 - Сформировали лосс
 - Умеем оптимизировать
 - Умеем принимать решение
- Но слишком много мы просто приняли на веру

Логистическая регрессия

- На этом вроде бы и все
 - Сформировали лосс
 - Умеем оптимизировать
 - Умеем принимать решение
- Но слишком много мы просто приняли на веру
- Почему и откуда именно?
 - $L = \log(1+e^{-M})$
 - $\sigma(M) = \frac{1}{1+\exp(-M)}$



Вероятностный подход



Минутка математики: Метод max правдоподобия

- Пусть $\mathbf{X}$ – вероятностное пространство с плотностью $p(x|\theta)$
 - θ – параметры распределения
- Примеры
 - $p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}; \theta_1=\mu; \theta_2=\sigma$
 - $p(x) = e^{-\lambda x}; \theta=\lambda$
- Имеем выборку X *iid* реализаций из $\mathbf{X}$
- Задача – оценить параметры θ по выборке
 - ММП – наиболее правдоподобные ;)

Минутка математики: Метод max правдоподобия

- Введем функцию правдоподобия
 - $L(X) = \prod_i^L p(x_i|\theta)$
 - Совместная вероятность наблюдать каждый из элементов I
 - Перемножаем, т.к. iid
- Метод максимального правдоподобия
 - $\theta' = \arg \max_{\theta} L(X)$
- *Вероятность выпадения орла методом ММП?*

ММП для нашей задачи

- Веса признаков – параметры нашей задачи
 - $p(x|\theta) \rightarrow p(x|w)$
- Оценить наиболее вероятные веса по выборке
- Решение – методом ММП
 - $w' = \arg \max_w L(X)$
 - $L(X) = \prod_i^L p(x_i|w) \rightarrow \max$
- $L(X) \rightarrow \max \quad \Rightarrow \log L(x) \rightarrow \max$

ММП для нашей задачи

- $L(X) \rightarrow \max \Rightarrow \log L(x) \rightarrow \max$
- $\log \prod_i^L p(x_i|w) = \sum_i^L \log p(x_i|w) \rightarrow \max$

ММП для нашей задачи

- $L(X) \rightarrow \max \Rightarrow \log L(x) \rightarrow \max$
- $\log \prod_i^L p(x_i|w) = \sum_i^L \log p(x_i|w) \rightarrow \max_w$
- *Ничего не напоминает ?*



Ресар: эмпирическая логика

- $Q'(w) = -\sum_i^L \log(p_i) \rightarrow \min_w$
- $Q'(w) = \sum_i^L \log(p_i) \rightarrow \max_w$ – максимизируем вероятности правильных классификаций
- $a(x_i, w_i) = \text{sign}(x_i, w_i) \leftrightarrow a(x_i, w_i) = \text{sign}\left(\frac{1}{1 + \exp(-(x_i, w_i))} - 0.5\right)$
- Можем даже уточнить алгоритм
 - $a(x_i, w_i) = \text{sign}\left(\frac{1}{1 + \exp(-(x_i, w_i))} - th\right)$

ММП для нашей задачи

- $L(X) \rightarrow \max \Rightarrow \log L(x) \rightarrow \max$
- $\log \prod_i^L p(x_i|w) = \sum_i^L \log p(x_i|w) \rightarrow \max_w$
- *Ничего не напоминает ?*
- Обосновали log-loss



Порождающая модель

Осталось определить $p(x_i/w)$

- В данной постановке x_i – пара объект-ответ (x_i, y_i)
- Пусть признаки – только бинарные $\{0,1\}$
 - Тогда порождающее распределение – Бернулли
- Можно доказать, что для Бернулли
 - $\frac{p(x, y=+1|w)}{p(x, y=-1|w)} = \exp(w, x)$
- Доказательство (beyond the scope)

Порождающая модель

Осталось определить $p(x_i/w)$

- $\frac{p(x, y=+1|w)}{p(x, y=-1|w)} = \exp(w, x)$
- Из полной вероятности
 - $p(x, y = -1|w) + p(x, y = +1|w) = 1$
- $p(x, y = +1|w) = \frac{1}{1+\exp\{-(w, x)\}}; p(x, y = -1|w) = \frac{1}{1+\exp\{(w, x)\}}$

Порождающая модель

Осталось определить $p(x_i|w)$

- $\frac{p(x, y=+1|w)}{p(x, y=-1|w)} = \exp(w, x)$
- Из полной вероятности
 - $p(x, y = -1|w) + p(x, y = +1|w) = 1$
- $p(x, y = +1|w) = \frac{1}{1+\exp\{-(w, x)\}}; p(x, y = -1|w) = \frac{1}{1+\exp\{(w, x)\}}$
- *Ничего не напоминает ?*
 - $p(x, y|w) = \frac{1}{1+\exp\{-M\}}$



Порождающая модель

Осталось определить $p(x_i|w)$

- $\frac{p(x, y=+1|w)}{p(x, y=-1|w)} = \exp(w, x)$
- Из полной вероятности
 - $p(x, y = -1|w) + p(x, y = +1|w) = 1$
- $p(x, y = +1|w) = \frac{1}{1+\exp\{-(w, x)\}}; p(x, y = -1|w) = \frac{1}{1+\exp\{(w, x)\}}$
- *Ничего не напоминает ? Обосновали сигмоиду*
 - $p(x, y|w) = \frac{1}{1+\exp\{-M\}}$



Логистическая регрессия на 1 слайд

- $L = \log(1+e^{-M})$
- $Q'(w) = \sum_i^L \log(1 + \exp(-M_i)) \rightarrow \min_w$
- Оптимизация градиентным спуском
- $a(x_i, w_i) = \text{sign}(x_i, w_i)$



**I Was Blind,
Now I See.**

John 9

Ресар

- Логистическая регрессия – алгоритм линейной классификации
 - Аппроксимирует эмпирический риск лог-лоссом
 - **или**
 - Порождает признаки из вероятностного пространства
 - Показали для Бернулли – бинарных признаков
 - *Но не для всех – сигмоиду нельзя трактовать как чистую вероятность. Но можно применять =)*
 - Оптимизирует лог-лосс
 - **или**
 - Решает задачу ММП
- Удобна для задач скоринга, спама
 - Важен не только аутпут, но и мера принадлежности


Recap



Empirical

Probabilistic

Метрики классификации



Метрики оценки

	true positive	false positive	true negative	false negative
y_pred	1			
y_true	1			

Метрики оценки

	true positive	false positive	true negative	false negative
y_pred	1	1		
y_true	1	0		

Метрики оценки

	true positive	false positive	true negative	false negative
y_pred	1	1	0	
y_true	1	0	0	

Метрики оценки

	true positive	false positive	true negative	false negative
y_pred	1	1	0	0
y_true	1	0	0	1

Метрики оценки: точность [Precision]

$$precision = \frac{tp}{tp + fp}$$


Метрики оценки: полнота [Recall]

$$recall = \frac{tp}{tp + fn}$$

Метрики оценки: f1 мера

$$f1 = \frac{2}{\frac{1}{precision} + \frac{1}{recall}}$$

Метрики оценки: f1 мера




Сбалансированная F-мера

Метрики оценки: f мера


$$f\beta = \frac{1 + \beta^2}{\frac{1}{precision} + \frac{\beta^2}{recall}}$$

Метрики оценки: f мера



F-мера с приоритетом полноты ($\beta^2 = 2$)

Метрики оценки: ROC AUC



- ROC AUC – площадь под кривой
 - ROC = Receiver Operator Characteristics
 - AUC = Area Under Curve
 - $0 < ROC\ AUC < 1$
 - Random Classifier: $ROC\ AUC = 0.5$

Метрики оценки: ROC AUC


- Упорядочим нашу выборку по убыванию предсказания

id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0

Метрики оценки: ROC AUC


- Упорядочим нашу выборку по убыванию предсказания
- Разбиваем квадрат 1×1 на
 - M (нули в выборке) вертикальных линий
 - N (единицы в выборке) горизонтальных

id	оценка	класс
4	0.6	1
1	0.5	0
6	0.3	1
3	0.2	0
5	0.2	1
2	0.1	0
7	0.0	0



Метрики оценки: ROC AUC

- Упорядочим нашу выборку по убыванию предсказания
- Разбиваем квадрат 1×1 на
 - M (нули в выборке) вертикальных линий
 - N (единицы в выборке) горизонтальных
- Идем по таблице сверху вниз
 - Встретили 1 – идем вверх
 - Встретили 0 – идем влево
 - Встретили одинаковые предсказания
 - m нулей и n единиц
 - Идем на m вправо и n вверх



Метрики оценки: ROC AUC

- Внутри квадрата – все пары точек 1 и 0 из выборки
- ROC отделяет верно упорядоченные алгоритмом пары точек
- ROC AUC – число верно отранжированных пар

Метрики оценки: ROC AUC

- Внутри квадрата – все пары точек 1 и 0 из выборки
- ROC отделяет верно упорядоченные алгоритмом пары точек
- ROC AUC – число верно отранжированных пар
- Исчерпывающая интерпретация:
 - Вероятность, что алгоритм верно упорядочит случайно выбранную пару (1,0)

Метрики оценки: Average Precision [PR AUC]

- Кривая precision – recall
- Метрика – площадь под кривой
- Площадь = интеграл = среднее значение $f(x)dx$
 - То есть среднее значение prec (recall) d recall
- Итого метрика показывает усредненное значение точности при разных порогах полноты